

佛法 DROS：奠定 Agent 世代的微核心溯源作業系統與具備不可否認性的 AgentWeb 安全基礎設施

Dharma DROS: Establishing the Microkernel Traceability Operating System and Non-Repudiable AgentWeb Security Infrastructure for the Agent Era

陳濬程 Jui-Cheng(Jimmy) Chen
康宸園有限公司/Top-Celestial Company Ltd.
Taipei, Taiwan R.O.C.
jimmychen@dr-os.io

Abstract—大型語言模型 (LLM) 先天存在不可預測的幻覺 (Hallucination) 問題，這在要求極端嚴謹的領域中是致命的缺陷。本研究最初致力於開發一套「AI 佛法推理系統」，然而我們發現，依賴傳統提示詞約束的模型極易發明虛假經文或曲解教義。為了根除此問題，我們開發了 Dharma Reasoning OS (佛法推理作業系統)：透過引入佛學中的「判教 (Doctrinal Classification)」機制作為硬性約束契約，並利用 C-FFI 技術在底層攔截 LLM 的執行路徑，我們成功實現了零幻覺的佛法推理。

基於此一成功經驗，我們意識到這套「契約約束 + C-FFI 物理阻斷」的核心架構，不僅適用於佛法，更是解決全球 AI Agent 治理問題的終極方案。因此，我們將其演進並泛化為 DROS (Deterministic Runtime Operating System) 架構。DROS 引入了傳統作業系統的「微核心 (Microkernel)」哲學，將 LLM 降級為純粹的「語義協同處理器 (Semantic Coprocessor)」，並由記憶體安全的 GuardVM 掌握 Ring 0 的絕對特權。透過硬編碼的 Vajra Contract (金剛合約) 與獨創的 T-Number 絕對溯源坐標系，DROS 實現了 100% 的可稽核性 (Auditability)，為企業級 Agent 部署奠定了絕對安全的憲法級基礎設施。

Index Terms—Microkernel, AgentWeb, Zero-Trust, C-FFI, Traceability, Prompt Injection, Non-Repudiation

I. 前言：從「判教」到「確定性治理」的演進

在建構自主智能體 (AI Agents) 的過程中，業界廣泛採用 LangChain 或 AutoGen 等單體式 (Monolithic) 框架。這些框架將語義生成與系統執行權限混為一談，高度依賴 LLM 的「自覺」來決定安全邊界。然而，用機率模型去約束另一個機率模型，不可避免地會面臨指令污染與幻覺越界的崩潰風險。

這個痛點在我們最初開發「數位佛堂」AI 推理系統時被無限放大。佛法教義的推演要求絕對的精準度，任何因模型幻覺而捏造的經文或偏離正法的論述都是無法被接受的。傳統的 RAG (檢索增強生成) 或 Prompt 限制根本無法壓制大模型發散的本能。

為了解決這個難題，我們回溯了古印度與中國佛教的「判教 (Panjiao / Doctrinal Classification)」傳統——即建立一套嚴格的教義衡量與邊界標準。我們開發了 Dharma Reasoning OS (佛法 DROS)，將判教機制

轉化為具備強制力的「約束契約 (Constraint Contracts)」。

當 LLM 進行佛法推理時，系統在底層利用 C-FFI (C Foreign Function Interface) 建立卡點；一旦 LLM 生成的推論試圖跨越判教契約的邊界，C-FFI 會直接在實體層面上觸發「物理熔斷 (Physical Melt)」，拒絕該次輸出。這套機制成功打造了世上首個不會產生幻覺的 AI 佛法推理系統。

從 Dharma 到 Deterministic：

在見證了這套防護機制的絕對威力後，我們進一步將其技術核心抽象化。我們發現，「佛法判教契約」在本質上與「企業資安合規政策」完全一致。因此，我們將 Dharma Reasoning OS 泛化升級為 DROS (Deterministic Runtime Operating System, 確定性執行期作業系統)。

它摒棄了對神經網路的盲目信任，回歸電腦科學最經典的安全設計——微核心架構，為所有領域的 Agent 應用提供了一套跨模型、跨平台的終極治理框架。

II. 核心哲學：AI 的微核心架構

作業系統發展史中，微核心 (μ -kernel) 架構以其極致的安全隔離與高穩定性著稱。DROS 將此哲學完美移植至 AI 治理領域：

- 1) **極簡核心 (Minimal Core)**：DROS 的核心引擎 GuardVM 被嚴格限制在數百行以內，並由記憶體安全的語言 (如 Rust、Go、C++) 撰寫。這極大地縮小了潛在的攻擊面。
- 2) **職責分離 (Separation of Concerns)**：「思考」發生在核心之外 (由 LLM 負責)，而「規則強制執行」則嚴格發生在核心之內 (由 CPU 負責)。
- 3) **預設封閉安全 (Fail-Closed Security)**：預設情況下，所有未經驗證的 LLM 行為都會被丟棄。只有當行為被 Vajra Contract 顯式允許，並且附帶有效的 T-Number 憑證時，才會被放行至執行層。

III. DROS 架構深潛

DROS 體系由四個關鍵層次構築而成，形成牢不可破的防護網：

A. LLM 協同處理器 (Semantic Coprocessor)

在 DROS 的世界觀中，LLM (如 GPT-4, Claude 3) 的地位被「降級」，不再是掌控全域的「決策者」，而是單純的「語義協同處理器」。它被餵入上下文並請求生成潛在的行動草案，但它完全不具備直接存取 API、資料庫或客戶端輸出的能力。

B. GuardVM (Supervisor Ring 0)

GuardVM 是運行於主機端的特權引擎，負責攔截 LLM 的串流位元組輸出。

- 它維護著當前對話的狀態機 (State Machine)。
- 它解析傳入的 LLM Token，並持續與載入的 Vajra Contract 進行比對。
- 如果 Token 串流違反了正規表示式 (Regex)、語義邊界或資料外洩規則，GuardVM 會瞬間中斷與 LLM 之間的 TCP/WebSocket 連線。

C. 金剛合約 (Vajra Contract：硬編碼約束)

不同於 LLM 隨時可能「遺忘」或被繞過的系統提示詞 (System Prompt)，Vajra Contract 是人類可讀、由領域專家撰寫的 Markdown 或 YAML 檔案。它如同硬體 ROM 一般，定義了系統的絕對邊界。這些合約不依賴 LLM 解析，而是由主機端 CPU 透過確定性的 C-FFI / Rust 邏輯直接評估。

D. C-FFI 轉換器 (VajraClaw Adapter)

為了支援多語言與商業化部署，DROS 利用 C-FFI (C Foreign Function Interfaces) 技術。無論是資料科學團隊的 Python 腳本、Web 後端的 Node.js，還是企業級的 Java 系統，都可以透過編譯好的共享函式庫 (如 vajra_claw.so) 享有完全一致、毫無語義漂移的物理層防護。

IV. T-NUMBER 絕對溯源與不可否認的密碼學簽章

DROS 憲法的核心要求是**絕對的溯源性 (Absolute Traceability)** 與 **不可否認性 (Non-Repudiation)**。當 LLM 提出任何事實陳述或執行工具時，它必須提供一個指向 Vajra Contract 授權條款的精確坐標，並由系統打上密碼學鋼印。

運作機制：

- 1) 人類專家的來源文件 (如企業資安規範) 被 DROS 解析，每一個段落/規則被賦予唯一的坐標，即 T-Number (例如 [T1-045])。
- 2) LLM 受到嚴格的底層指令約束：「對於每一個宣告或行動，必須附加上授權的 T-Number」。
- 3) GuardVM 攔截輸出。如果發現行動缺少 T-Number，或是該 T-Number 邏輯上不允許該行動 (由 CPU 確定性評估)，該輸出將被立即**熔斷 (Melted)**。
- 4) **不可否認的加密簽章 (DROS-by-execution PKI)**：若行動被允許，系統會利用非對稱加密技術為該次微小執行 (Per-Execution) 簽發一組無法篡改的數位憑證。

這套機制完美滿足了 HIPAA、SOC2 等嚴格的法律與財務合規稽核，因為 AI 的每一個微小舉動，不僅在物理層面上錨定到了人類簽署的文件上，更留下了絕對無法篡改與抵賴的加密鐵證。

V. 物理熔斷 vs. 提示詞工程

DROS 的物理熔斷機制與傳統防禦在本質上有著巨大差異，如表 I 所示：

TABLE I
傳統機率性防禦與 DROS 確定性物理熔斷之對比

評估維度	提示詞工程 / RAG 軟邊界	DROS 物理熔斷
強制執行層	LLM 神經網路權重 (機率性)	主機端 CPU 記憶體 (確定性)
對注入的反應	若被欺騙可能道歉並服從	瞬間砍斷 TCP 連線 (abort())
安全檢查成本	高 (需二次呼叫 LLM)	零 (CPU 端執行 Regex/AST)
可稽核性	黑盒子 (Black Box)	100% 透明溯源 (T-Number)

VI. 部署拓撲與全域覆蓋

這套基礎設施被設計為能無縫適應多層次的部署拓撲，讓 AgentWeb 的安全網能覆蓋從雲端到終端的每一個角落：

- 1) **雲端原生邊緣 (Cloud-Native Edge)**：適用於要求極低延遲的 Web 應用，部署於 Kubernetes 或 Cloudflare Workers。
- 2) **企業內部 API (Enterprise Internal API)**：部署於企業 VPC 內部，提供給 HR、法務或財務的內部 AI 助理使用。
- 3) **物理隔離主權級 (Air-Gapped Sovereign)**：針對國防軍工、財星 500 大企業或受到高度監管的主權網路，提供 100% 離線運行、零遙測與硬體 UUID 綁定的極致防護。
- 4) **終端設備與手機 SDK (Mobile & Edge SDK)**：將核心的 C-FFI 攔截引擎封裝為極輕量級的 Vajra-Claw 手機 SDK，讓防護網能直接部署於使用者的 iOS 或 Android 裝置上。這種從雲端叢集一路延伸到個人口袋的終極防護，確保了 AgentWeb 在任何層次都受到同一套確定性標準的治理。

VII. 結論與未來展望

DROS 首部曲重新定義了 Agent 世代的「作業系統憲法」。透過捨棄對機率模型的依賴，引入微核心哲學、T-Number 坐標系與物理熔斷機制，DROS 成功將 LLM 從一個「不可控的黑盒子決策者」馴化為一個「安全受控的語義協同處理器」。

然而，單機的安全治理只是一個起點。隨著 AI 走入全球協作網絡，我們面臨的下一個挑戰是如何在不同信任域的 Agents 之間建立互信。因此，本研究所奠定的微核心與 T-Number 溯源基礎，將自然導向 DROS 體系的下一個核心里程碑：**AgentWeb 信任網路與不可否認的加密簽章 (DROS-by-Execution PKI)** 基礎設施。

透過為大模型的每一個微小執行動作 (Per-Execution) 打上具備密碼學效力的憑證鋼印，我們將在充滿未知的 Agent 世代中，實現一個「**凡走過必留下鐵證、完全有跡可循**」的安全協作網絡。這套兼具「佛法約束」與「零信任密碼學」的終極基礎設施，將引領人類社會安全地跨入下一個 AI 黃金十年。

REFERENCES

- [1] J. Liedtke, “On Micro-Kernel Construction,” *ACM SIGOPS Operating Systems Review*, 1995.
- [2] S. Bubeck et al., “Sparks of Artificial General Intelligence: Early experiments with GPT-4,” *arXiv*, 2023.
- [3] K. Greshake et al., “More than you’ve asked for: A Comprehensive Analysis of Novel Prompt Injection Threats to Application-Integrated Large Language Models,” 2023.
- [4] S. Rose, O. Borchert, S. Mitchell, and S. Connelly, “Zero Trust Architecture,” *NIST Special Publication 800-207*, Aug. 2020.

AI 輔助技術聲明 (DECLARATION OF AI-ASSISTED TECHNOLOGIES)

在撰寫本論文與開發原型系統的過程中，作者利用了大型語言模型（包括但不限於 Google Gemini 系列）協助進行學術文獻翻譯、程式碼框架生成、以及排版校對。作者對本文的所有邏輯架構、核心哲學（包含微核心架構與 T-Number 絕對溯源）與最終內容承擔完全責任，並已對 AI 生成之內容進行了嚴格的審查與驗證。